

Predicción de la demanda de servicios de ambulancia para la planeación operativa

1st Yeison Ochoa Cárdenas

Facultad de Ingeniería

Universidad de Antioquia

Medellín, Antioquia

yeison.ochoa@udea.edu.co

Resumen—Este documento se centra en el problema de predecir la demanda de servicios de ambulancia para cada hora del día. El objetivo es saber cuántas ambulancias se necesitarán en cada momento para tomar decisiones sobre la disponibilidad de la flota, la planificación de turnos y la asignación de recursos. Se utilizó un conjunto de datos históricos de incidentes del servicio de emergencias médicas de Nueva York para crear una serie temporal horaria. Esta serie se enriqueció con información sobre el calendario, la demanda pasada, el tipo de llamada, la gravedad de la situación, la ubicación y el tiempo de respuesta.

Se compararon varios modelos para predecir la demanda de servicios de ambulancia. Algunos de estos modelos incluyeron regresión regularizada, regresión de vectores de soporte, redes neuronales y métodos conjunto basados en árboles. El modelo que mejor funcionó fue una combinación de dos técnicas llamadas HistGradientBoostingRegressor y XGBoost. El resultado fue que este modelo combinado funcionó mejor que cualquier otro modelo individual y logró predecir la demanda de servicios de ambulancia con un menor error. Los resultados muestran que el enfoque propuesto es capaz de capturar los patrones de demanda regulares por hora y por semana, aunque los periodos de demanda extrema siguen siendo un desafío para predecir con precisión.

Palabras clave—pronóstico de demanda, servicios médicos de emergencia, ambulancias, aprendizaje supervisado, regresión, series de tiempo, planeación operativa.

Abstract—This paper focuses on the problem of predicting ambulance service demand for each hour of the day. The goal is to determine how many ambulances will be needed at any given time to inform decisions about fleet availability, shift planning, and resource allocation. A historical dataset of New York City emergency medical services incidents is used to create an hourly time series. This series is enriched with information on the calendar, past demand, call type, severity of the situation, location, and response time.

Several models for predicting ambulance service demand were compared. These models included regularized regression, support vector regression, neural networks, and tree-based conjoint methods. The best-performing model was a combination of two techniques called HistGradientBoostingRegressor and XGBoost. This combination performed better than any of the individual models and predicted ambulance service demand with less error. The results show that the proposed approach is able to capture regular hourly and weekly demand patterns, although extreme demand periods remain a challenge to predict accurately.

Index Terms—demand forecasting, emergency medical services, ambulance dispatch, supervised learning, regression, time series, operational planning.

I. INTRODUCCIÓN

Los servicios médicos de emergencia operan en un entorno muy variable. La demanda de estos servicios puede cambiar mucho de un día a otro debido a factores como la hora del día, el día de la semana y la época del año. Es importante saber cuántos servicios de ambulancia se necesitan en los próximos días. Esto permite planificar mejor los recursos y asegurarse de que haya suficientes ambulancias disponibles. Si no se estima correctamente la demanda, puede haber demoras en la atención, no se puede cubrir todo el servicio o se utilizan ambulancias y personal de manera ineficiente.

Este proyecto busca resolver este problema utilizando técnicas de aprendizaje automático para predecir la demanda de servicios médicos de emergencia. Se utilizarán datos históricos del sistema de despacho de servicios médicos de emergencia de Nueva York para construir un modelo que pueda estimar el número de servicios de ambulancia que se necesitarán en un futuro cercano.

El objetivo es crear un modelo que pueda predecir con precisión el número de servicios de ambulancia que se necesitarán en un determinado período de tiempo y también mostrar como el análisis de datos históricos puede ser una herramienta útil para mejorar la planificación en sistemas de atención prehospitalaria.

II. DESCRIPCIÓN DEL PROBLEMA

Los servicios médicos de emergencia cumplen un papel muy importante en los sistemas de salud urbana. Son los responsables de responder rápidamente cuando alguien necesita atención médica de inmediato. En ciudades con mucha gente, es un desafío organizar bien las ambulancias, el personal médico y los recursos.

La cantidad de incidentes médicos no es la misma todo el tiempo. La hora del día, el día de la semana, los días festivos, el tipo de incidente y el lugar donde ocurren pueden influir mucho en la cantidad de incidentes. Esto hace que sea difícil planificar cuando solo se utilizan números promedio del pasado o reglas fijas para asignar recursos. Aquí es donde el aprendizaje automático es muy útil. Estos métodos pueden entender patrones complicados y relaciones que no son lineales en grandes cantidades de datos del pasado.

Si podemos predecir con precisión la cantidad de incidentes que ocurrirán cada hora, podemos hacer cosas como:

- Planificar mejor la capacidad de los servicios médicos de emergencia.
- Distribuir las ambulancias de manera estratégica.
- Optimizar el personal disponible.
- Reducir el tiempo que toma responder a una emergencia.
- Aprovechar mejor los recursos médicos.

Para desarrollar este proyecto, usamos datos sobre incidentes médicos en Nueva York. Estos datos tienen registros de mucho tiempo y nos ayudan a entender cómo atender la demanda médica en la ciudad.

Primero, juntamos los datos en grupos de una hora. Así, creamos una base de datos grande con la información.

La base de datos final utilizada para modelamiento contiene aproximadamente 136,416 muestras (horas observadas). La variable objetivo corresponde al número total de incidentes registrados en una hora específica.

Las variables predictoras pueden agruparse en diferentes categorías:

- Variables temporales: nos dicen sobre el calendario y los patrones de tiempo, como el año, mes, día, hora, día de la semana, si es fin de semana o si es un día festivo. Estas nos ayudan a ver patrones diarios, semanales y anuales.
- Variables operacionales del sistema EMS: nos hablan sobre los incidentes, como el tipo de llamada, cuán grave es el incidente, si hay eventos especiales, transferencias, reaperturas, etc.

Debido al carácter categórico de varias variables, se utilizó codificación One-Hot Encoding, generando variables binarias para representar cada categoría relevante.

- Variables geográficas: nos dicen en qué parte de la ciudad pasó el incidente, como Brooklyn, Manhattan, Bronx, Queens, Staten Island, etc. Estas variables también fueron transformadas utilizando codificación binaria
- Variables de desempeño: nos hablan sobre cuánto tiempo toma responder a los incidentes como tiempo promedio de despacho, tiempo promedio de respuesta del incidente y tiempo promedio de desplazamiento.
- Variables derivadas: creamos nuevas variables para ver cómo cambia la demanda con el tiempo, como promedios y máximos en diferentes ventanas de tiempo.

– Rezagos temporales (lags):

- * lag 1 hora
- * lag 24 horas
- * lag 168 horas (1 semana)

– Estadísticas móviles:

- * medias móviles.
- * máximos móviles.
- * desviaciones estándar móviles.

Estas características fueron calculadas sobre diferentes ventanas temporales con el objetivo de capturar tendencias recientes, estacionalidad y comportamiento histórico.

Algunos datos faltaban, especialmente cuando se hacían cálculos que necesitaban información de antes. Para solucionar esto, se eliminaron algunas filas de datos que no tenían suficiente información histórica. No se hizo mucho para completar datos que faltaban porque no había muchos espacios vacíos en los datos originales. Así, nos aseguramos de tener una buena base para el proyecto.

Se utilizó un enfoque de aprendizaje supervisado, específicamente para predecir una cantidad numérica continua, como la cantidad de incidentes médicos esperados por hora. Se eligió este enfoque porque la variable que se quiere predecir es un valor numérico continuo. El objetivo es encontrar una función que pueda predecir este valor con precisión.

La función se puede representar de la siguiente manera:

$$f(X_t) \rightarrow \hat{y}_t$$

donde X es el conjunto de variables que se utilizan para hacer la predicción, y es el valor real observado y $\hat{y}$ es el valor estimado por el modelo.

Como el problema involucra datos que cambian con el tiempo, se utilizó una estrategia de partición de los datos en diferentes momentos. Esto se hace para evitar mezclar los datos de entrenamiento y evaluación de manera aleatoria.

El conjunto de datos se dividió en tres partes:

- 70% para entrenamiento
- 15% para validación
- 15% para prueba

Se probaron diferentes enfoques para crear el modelo y los mejores resultados se obtuvieron mediante un ensamble entre HistGradientBoostingRegressor y XGBoost, mostrando el menor error de predicción sobre el conjunto de prueba.

III. ESTADO DEL ARTE

La predicción de demanda en servicios médicos de emergencia se ha abordado de diferentes maneras. Algunos estudios utilizan modelos clásicos de series de tiempo para predecir la demanda total. Otros utilizan modelos estadísticos para variables de conteo o métodos de aprendizaje de máquina que incluyen componentes espaciales y temporales. En general, se considera que predecir la cantidad de llamadas, incidentes o despachos de ambulancias es útil para tomar decisiones sobre la cobertura, capacidad operativa y redistribución de recursos.

Un primer estudio importante es el de Monks et al. [1] estos investigadores desarrollaron un modelo para predecir la cantidad diaria de llamadas que requieren el despacho de una o más ambulancias en Inglaterra y Gales. Los autores comparan un modelo con más de 14 métodos estándar de pronóstico y finalmente seleccionan un ensamble entre Prophet y regresión con errores ARIMA. La metodología de validación utilizada fue time series cross-validation, aplicada sobre ocho series temporales, y las métricas principales fueron MASE y la cobertura de intervalos de predicción al 80% y 95%. MASE es una métrica utilizada para evaluar la precisión de modelos de pronóstico, la cual mide el error absoluto medio escalado respecto al error obtenido por un método ingenuo de referencia, permitiendo comparar el rendimiento

entre diferentes series temporales. Como resultado, el modelo benchmark alcanzo un MASE de 0.68 en el escenario de simulación y 0.73 en la validación externa, mostrando que el enfoque es útil para la planeación de servicios de ambulancia.

Un segundo estudio es el de Andreella et al. [2] estos investigadores propusieron un modelo para predecir el volumen de eventos de emergencia en Lombardía, Italia. En este caso el problema fue tratado como un pronostico de conteos y se utilizo un modelo autorregresivo aditivo con distribución binomial negativa y smoothing splines, capaz de predecir eventos a 1, 2, 5 y 7 días. Para la selección final del modelo se empleo una validación cruzada que tiene en cuenta la dependencia temporal, y el desempeño se comparo con otras alternativas usando MAPE. Este estudio es útil para nuestro trabajo porque muestra que los modelos de conteo son una buena alternativa para predecir la demanda diaria.

Un tercer estudio es el de Martin, Mousavi y Saydam [3] quienes abordaron el problema de la predicción de demanda de servicios médicos de emergencia desde una perspectiva de aprendizaje de maquina espacio-temporal. Estos generaron predicciones diarias, horarias y espaciales del volumen de llamadas mediante una red neuronal multicapa, después de realizar selección de variables con un modelo basado en arboles y agrupamiento espacial con K-Means. Se comparo contra metodos tradicionales de series de tiempo y los resultados mostraron que el modelo MLP supero a los enfoques tradicionales, especialmente cuando la predicción se realiza a niveles espaciales más finos. Este estudio es valioso porque demuestra que es posible incorporar una dimensión espacial y temporal mas detallada para mejorar la planeación de ambulancias.

Un cuarto estudio importante es el de Vile et al. [4] donde exploraron el uso de Singular Spectrum Analysis (SSA) para mejorar la predicción de demanda de ambulancias en el Welsh Ambulance Service Trust. SSA es una técnica de análisis de series temporales que descompone los datos en componentes como tendencia, periodicidad, estacionalidad y ruido mediante métodos algebraicos basados en descomposición en valores singulares. El estudio mostro que el método SSA supero a otros métodos de pronostico en horizontes de pronostico mas largos. Aunque no utiliza el mismo conjunto de datos que nuestro proyecto, si aborda el mismo problema de estimar la demanda futura de ambulancias para fines operativos.

Además de estos estudios, existen otros que utilizan la misma fuente de datos o una equivalente para estudiar el comportamiento operativo del sistema de servicios médicos de emergencia. Por ejemplo, Pitt (2022) analizo datos prehospitalarios del FDNY y encontró una caída interanual del volumen de llamadas. Este estudio no se enfoca en la predicción, pero si confirma que el conjunto de datos es válido para la investigación operativa y análisis de desempeño del sistema.

En resumen, el problema de predecir la demanda de servicios médicos de emergencia puede abordarse de forma valida con modelos de series de tiempo, modelos estadísticos para conteos y enfoques de aprendizaje de máquina.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

A. Metodología de validación

El problema que estamos tratando es predecir lo que pasará en el futuro en una serie de datos que cambian con el tiempo. Por eso, no podemos usar los métodos normales para comprobar si nuestro modelo es bueno, porque podríamos estar utilizando información que no deberíamos.

Por eso, decidimos dividir los datos en partes según el tiempo, para que el orden en el que las cosas sucedieron se mantuviera intacto.

La forma en que los dividimos fue:

Conjunto	Proporción	Número de muestras
Entrenamiento	70%	95,491
Validación	15%	20,462
Test	15%	20,463

TABLE I

DISTRIBUCIÓN DEL CONJUNTO DE DATOS EN ENTRENAMIENTO, VALIDACIÓN Y PRUEBA.

Los rangos temporales utilizados fueron:

Conjunto	Periodo
Train	2005–2015
Validation	2015–2018
Test	2018–2020

TABLE II

PERIODOS TEMPORALES UTILIZADOS PARA LOS CONJUNTOS DE ENTRENAMIENTO, VALIDACIÓN Y PRUEBA.

El conjunto de entrenamiento se usó para ajustar los parámetros internos de los modelos.

El conjunto de validación se utilizó para:

- buscar hiperparámetros
- comparación de arquitecturas
- seleccionar modelos

Finalmente, el conjunto de test se mantuvo completamente aislado durante el desarrollo experimental y se usó solo para estimar el desempeño final del sistema. No fue necesario aplicar técnicas de submuestreo ni sobremuestreo, porque el problema es una tarea de regresión y no de clasificación desbalanceada.

B. Modelos evaluados

Para comparar diferentes formas de aprendizaje automático, se analizaron varios modelos de aprendizaje que pertenecen a diferentes grupos de métodos.

- Modelo paramétrico basado en regresión:

Este modelo es una especie de regresión lineal, pero con una variante llamada Ridge Regression. La Ridge Regression es una forma de regresión lineal que incorpora una penalización sobre los coeficientes del modelo, lo que se conoce como penalización L2. Este modelo sirve como una aproximación lineal de referencia, es decir, se utiliza como un punto de partida para comparar con otros modelos.

- Modelo no paramétrico:

Este modelo es una Máquina de Vectores de Soporte para Regresión, o SVR. La SVR es capaz de modelar relaciones no lineales entre variables, lo que la hace muy útil en escenarios complejos. Los modelos SVR son especialmente útiles cuando las fronteras entre las variables predictoras y la variable objetivo son complicadas.

- Modelo basado en ensamble de árboles:
Se han implementado dos algoritmos de ensamble de árboles. El primero es el HistGradientBoostingRegressor, o HGBR, y el segundo es el XGBoost. Estos métodos permiten capturar relaciones muy complejas entre variables y manejar interacciones entre ellas.
- Red neuronal artificial:
La arquitectura utilizada es la GRU, o Gated Recurrent Unit, que es una especie de red neuronal recurrente. La GRU es capaz de modelar dependencias temporales en secuencias de datos, lo que la hace muy útil para ciertos tipos de problemas.
- Modelo de ensamble final:
Finalmente, se ha implementado un modelo de ensamble final. Este modelo combina los algoritmos HGBR y XGBoost, buscando aprovechar las fortalezas de cada uno. El objetivo es mejorar el desempeño del modelo, combinando las ventajas de ambos algoritmos.

C. Hiperparámetros evaluados

Durante la experimentación se exploraron diferentes configuraciones de hiperparámetros para cada modelo.

Modelo	Hiperparámetro	Valores evaluados
Ridge	α	0.1, 1, 10, 100
SVR	C	1, 10, 50
SVR	gamma	scale, auto
SVR	kernel	rbf
HGBR	learning_rate	0.03, 0.05
HGBR	max_iter	300, 500, 600, 800
HGBR	max_depth	6, 8, 10
HGBR	min_samples_leaf	20, 30
XGBoost	n_estimators	400, 600, 800, 1000
XGBoost	max_depth	6, 8, 10
XGBoost	learning_rate	0.02, 0.03, 0.05
XGBoost	subsample	0.8, 0.9
GRU	epochs	20, 40
GRU	hidden_size	64, 128
GRU	learning_rate	0.001

TABLE III

HIPERPARÁMETROS Y VALORES EVALUADOS DURANTE EL PROCESO DE AJUSTE DE MODELOS.

Los hiperparámetros óptimos fueron seleccionados con base en el menor error obtenido sobre el conjunto de validación.

D. Métricas de evaluación

Para evaluar el rendimiento predictivo del sistema se emplearon tres métricas complementarias.

- Error Absoluto Medio (MAE)

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

Mide el error promedio absoluto entre los valores reales y los valores predichos.

- Raíz del Error Cuadrático Medio (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Penaliza más severamente los errores grandes. Esto es especialmente importante en este problema porque hay picos muy altos de demanda.

- Weighted Mean Absolute Percentage Error (wMAPE)

$$wMAPE = \frac{\sum |y_i - \hat{y}_i|}{\sum |y_i|} \times 100$$

Esta métrica muestra el error porcentual en relación con el volumen total de demanda. Es útil para predecir la demanda en la operación diaria porque ayuda a entender cuán grande es el error.

E. Resultados del entrenamiento de Modelos

Para empezar, se evaluaron modelos sencillos que se basaban en rezagos temporales.

Modelo	Test MAE	Test RMSE	Test wMAPE
Lag 1	19.95	25.16	11.48%
Lag 24	22.43	29.79	12.90%
Lag 168	19.78	26.54	11.38%

TABLE IV

RESULTADOS DE DESEMPEÑO EN EL CONJUNTO DE PRUEBA PARA LOS MODELOS BASELINE BASADOS EN VARIABLES REZAGADAS.

Los resultados muestran que, aunque los modelos baseline logran capturar cierta periodicidad temporal, presentan errores considerablemente superiores frente a modelos de aprendizaje automático más avanzados.

Modelo	Validación MAE	Test MAE	Test RMSE	Test wMAPE
Ridge	13.56	13.87	17.81	7.98%
GRU	15.45	21.10	28.02	12.13%
HGBR	12.12	13.13	17.14	7.56%
XGBoost	11.91	13.15	17.39	7.57%
SVR	13.28	17.61	17.61	7.99%
Ensamble HGBR+XGB	11.89	12.97	16.98	7.46%

TABLE V

COMPARACIÓN DEL DESEMPEÑO DE LOS MODELOS EVALUADOS USANDO MÉTRICAS DE VALIDACIÓN Y PRUEBA.

El mejor desempeño global fue obtenido mediante el ensamble HGBR + XGBoost, una vez seleccionado el modelo, se comparó la serie temporal real con las predicciones obtenidas sobre el conjunto de prueba.




Fig. 1. Comparación entre valores reales y predichos del modelo ensamble.

Debido a que la serie completa tiene mucha información en un poco tiempo, se decidió ver una semana en detalle para evaluar cómo sigue el modelo en cada lugar.




Fig. 2. Comparación detallada de demanda real y predicha durante una semana.

Dado que los eventos con mucha demanda son uno de los mayores desafíos, evaluamos cómo se comporta el modelo durante las horas de máxima demanda.




Fig. 3. Predicción del modelo sobre las horas de mayor demanda.

Además, se estudió la capacidad del modelo para reproducir tendencias generales utilizando el promedio diario de la demanda.




Fig. 4. Demanda diaria promedio real y estimada

V. REDUCCIÓN DE DIMENSIÓN

En esta etapa, se evaluaron diferentes formas de reducir la cantidad de variables para ver si se podía hacer que el modelo final fuera más simple sin que esto afectara negativamente su capacidad para predecir resultados.

Los modelos que funcionaron mejor en la Sección 4, como HGBR y XGBoost, se volvieron a probar con los nuevos conjuntos de características que se habían generado.

A. Análisis individual de variables

Como primer paso, se examinó cada variable por separado para ver cómo se relacionaban con la demanda horaria.

El propósito era encontrar atributos que fueran muy útiles para explicar las cosas y variables que no fueran muy importantes o que dijeran lo mismo que otras.

Variable	Correlación
demanda_horaria_lag_1	0.892
demanda_horaria_lag_168	0.880
demanda_horaria_lag_24	0.836
borough_BROOKLYN_lag_1	0.818
borough_MANHATTAN_lag_1	0.803
demanda_horaria_ma_3	0.801
borough_QUEENS_lag_1	0.796
borough_BRONX_lag_1	0.795

TABLE VI
VARIABLES CON MAYOR CORRELACIÓN RESPECTO A LA DEMANDA HORARIA.

Los resultados indican que las variables que mejor pueden predecir el futuro están muy relacionadas con lo que ha pasado recientemente en la demanda. En particular, los cambios que ocurren en un mismo día, en días de la semana específicos y en semanas enteras son muy importantes.

Asimismo, se encontraron variables con correlaciones muy bajas. Estas podrían ser eliminadas.

Variables
sev_9_lag_1
sev_9_lag_24
sev_9_lag_168
transfer_flag_lag_1
transfer_flag_lag_24
transfer_flag_lag_168
borough_UNKNOWN_lag_1
borough_UNKNOWN_lag_24
borough_UNKNOWN_lag_168
mes

TABLE VII
VARIABLES DESCARTADAS DURANTE EL PROCESO DE SELECCIÓN DE CARACTERÍSTICAS.

Aunque cada una de estas variables por sí sola no muestra una relación muy fuerte, no se eliminaron cuando se creó el sistema final. Esto se debe a que los modelos que usan árboles pueden encontrar conexiones no lineales entre atributos que parecen ser débiles.

B. Extracción de características lineal

Para reducir la cantidad de dimensiones de manera lineal, se utilizó el análisis de componentes principales.

El criterio que se utilizó para seleccionar las dimensiones fue conservar alrededor de 95 por ciento de la varianza acumulada. El objetivo era mantener la mayor cantidad de información posible del conjunto original de datos.

El método logró reducir el espacio original que tenía 139 variables a 77 componentes principales. Esto representa una reducción del 44,6 por ciento en el número de dimensiones.

Luego, se volvieron a evaluar los dos mejores modelos que se habían identificado anteriormente: HGBR y XGBoost.

Modelo	Variables	Reducción	MAE	RMSE	wMAPE
HGBR original	139	—	12.12	15.87	7.29%
HGBR + PCA	77	44.6%	14.75	19.55	8.49%
XGB original	139	—	11.91	15.48	7.17%
XGB + PCA	77	44.6%	15.24	20.15	8.77%

TABLE VIII
COMPARACIÓN DEL DESEMPEÑO DE LOS MODELOS ORIGINALES Y LOS MODELOS CON REDUCCIÓN DE DIMENSIONALIDAD MEDIANTE PCA.

Los resultados muestran que el desempeño empeora después de aplicar PCA. Aunque el número de variables se redujo casi la mitad, ambos modelos aumentaron sus errores de predicción.

Esto sugiere que la transformación lineal de PCA elimina parte de la información útil para predecir contenida en las variables originales. Sobre todo, relaciones que dependen del tiempo y dependencias complejas que los modelos basados en árboles aprovechan eficientemente.

C. Extracción de características no lineal

Como alternativa, se utilizó Uniform Manifold Approximation and Projection (UMAP).

Se eligió un embedding de 20 componentes. Esto fue para encontrar un equilibrio entre la compresión de dimensiones y la capacidad de predicción.

El método redujo las 139 variables originales a 20 componentes. Esto significa una reducción del 85.6

Luego, se volvieron a evaluar HGBR y XGBoost.

Modelo	Variables	Reducción	MAE	RMSE	wMAPE
HGBR original	139	—	12.12	15.87	7.29%
HGBR + UMAP	20	85.6%	16.94	22.62	9.75%
XGB original	139	—	11.91	15.48	7.17%
XGB + UMAP	20	85.6%	16.70	22.34	9.61%

TABLE IX

COMPARACIÓN DEL DESEMPEÑO DE LOS MODELOS ORIGINALES Y LOS MODELOS CON REDUCCIÓN DE DIMENSIONALIDAD MEDIANTE UMAP.

Aunque UMAP logró una reducción dimensional mucho mayor que PCA, el desempeño predictivo empeoró mucho.

Esto muestra que la representación reducida de UMAP no conservó toda la información temporal y estructural necesaria para predecir la demanda horaria.

VI. DISCUSIÓN Y CONCLUSIONES

Los resultados de los experimentos muestran diferencias significativas entre las familias de modelos evaluadas para predecir la demanda horaria de servicios médicos de emergencia.

El modelo Ridge Regression tuvo un desempeño aceptable, pero no tan bueno como los métodos no lineales. Esto sugiere que el problema tiene relaciones complejas que no se pueden modelar solo con combinaciones lineales.

El modelo Gradient Boosting Regressor tuvo el peor desempeño, especialmente en términos de error cuadrático medio y error porcentual absoluto ponderado. Aunque logró un error absoluto medio competitivo, su alta sensibilidad a errores grandes indica que tiene dificultades para modelar eventos extremos y picos de demanda.

Entre los modelos individuales, HGBR, XGBoost y SVR obtuvieron los mejores resultados. XGBoost alcanzó el menor error de validación, mientras que SVR obtuvo un desempeño competitivo en la prueba.

El mejor resultado se obtuvo combinando HGBR y XGBoost, logrando:

- Validación: 11.39
- Prueba: 12.97
- Error cuadrático medio en prueba: 16.98

- Error porcentual absoluto ponderado en prueba: 7.46%

Estos resultados muestran una mejora respecto a los modelos individuales, lo que confirma que combinar modelos basados en boosting permite aprovechar fortalezas complementarias y mejorar la generalización.

En el análisis gráfico, se observó que el modelo reproduce correctamente la tendencia general, los patrones diarios y semanales, así como gran parte de las fluctuaciones normales del sistema. Sin embargo, los mayores errores se concentran en horas con picos extremos de demanda, lo cual es común en sistemas EMS reales.

Los resultados que obtuvimos tienen sentido con lo que ya se ha investigado. Al igual que Monks y su equipo, se encontró que combinar diferentes enfoques puede ser mejor que usar un solo modelo para predecir la demanda de ambulancias. También con Andreella y su equipo en que la información temporal y las variables que se autorregulan son clave.

El trabajo también se alinea con lo que Martin, Mousavi y Saydam descubrieron sobre la utilidad de los modelos de aprendizaje automático para detectar patrones complejos en el espacio y el tiempo. Sin embargo, en este caso, los métodos de boosting funcionaron mejor que las redes neuronales.

En resumen, los modelos que combinan árboles resultaron ser la mejor estrategia para este problema. Ofrecen un buen equilibrio entre precisión, resistencia a cambios no lineales y capacidad para modelar patrones temporales complejos en datos reales de servicios médicos de emergencia.

REFERENCES

- [1] T. Monks, A. Harper, M. Allen, L. Collins, and A. Mayne, "Forecasting the daily demand for emergency medical ambulances in England and Wales: A benchmark model and external validation," *BMC Medical Informatics and Decision Making*, vol. 23, p. 117, 2023. [Online]. Available: <https://link.springer.com/article/10.1186/s12911-023-02218-z>
- [2] A. Andreella, A. Mira, S. Balafas, E.-J. C. Wit, F. Ruggeri, G. Nattino, G. Ghilardi, and G. Bertolini, "A predictive model for planning emergency events rescue during COVID-19 in Lombardy, Italy," *Statistical Methods & Applications*, vol. 33, no. 2, pp. 635–659, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s10260-023-00725-x>
- [3] R. J. Martin, R. Mousavi, and C. Saydam, "Predicting emergency medical service call demand: A modern spatiotemporal machine learning approach," *Operations Research for Health Care*, vol. 28, p. 100285, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S2211692321000011>
- [4] D. Neira-Rodado, J. C. Paz-Roa, J. W. Escobar, and M. A. Ortiz-Barrios, "A novel machine learning approach for spatiotemporal prediction of EMS events: A case study from Barranquilla, Colombia," *Heliyon*, vol. 11, no. 2, p. e41904, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2405844025002841>
- [5] City of New York, "EMS Incident Dispatch Data," NYC Open Data, 2025. [Online]. Available: <https://data.cityofnewyork.us/Public-Safety/EMS-Incident-Dispatch-Data/76xm-jjuj>
- [6] M. Vile, A. Gillard, and S. Harper, "Improving ambulance demand forecasting using Singular Spectrum Analysis," *Health Systems*, vol. 11, no. 1, pp. 45–61, 2022. [Online]. Available: <https://doi.org/10.1080/20476965.2021.1889597>
- [7] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001. [Online]. Available: <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-a-gradient-boosting-machine/10.1214/aos/1013203451.full>

- [8] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 785–794. [Online]. Available: <https://dl.acm.org/doi/10.1145/2939672.2939785>
- [9] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995. [Online]. Available: <https://link.springer.com/article/10.1007/BF00994018>
- [10] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. New York, NY, USA: Springer, 2002.
- [11] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” arXiv:1802.03426, 2018. [Online]. Available: <https://arxiv.org/abs/1802.03426>
- [12] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer, 2009. [Online]. Available: <https://hastie.su.domains/ElemStatLearn/>
- [13] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Available: <https://www.deeplearningbook.org/>
- [14] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>